Clustering des données immobilières californiennes

Bloc IA – Prosit 1

24 mars 2026

1 Description des données

Le jeu de données `housing.csv` contient **20 640 enregistrements** issus du recensement californien de 1990. Chaque ligne correspond à un *block group* (plus petite unité administrative, 500 à 5 000 habitants).

Table 1 – Variables du dataset

Variable	Type	Description
`longitude / latitude`	float	Coordonnées géographiques
`housing_median_age`	float	Âge médian des logements
`total_rooms`	float	Nombre total de pièces
`total_bedrooms`	float	Nombre total de chambres
`population`	float	Population du block group
`households`	float	Nombre de ménages
`median_income`	float	Revenu médian (en dizaines de k$)
`median_house_value`	float	Prix médian du logement ($)
`ocean_proximity`	cat.	Proximité à l'océan

Valeurs manquantes : seule `total_bedrooms` présente 207 valeurs nulles. Les 4 variables utilisées pour le clustering n'en contiennent aucune.

2 Choix méthodologiques

1. **Sélection des variables** : `latitude`, `longitude`, `median_income`, `median_house_value`. Ces variables captent à la fois la position géographique et le profil socio-économique de chaque zone.
2. **Standardisation** : `StandardScaler` (centrage–réduction) appliqué aux 4 variables afin qu'aucune ne domine le calcul de distance euclidienne.
3. **Algorithme** : **KMeans** – simple, rapide et bien adapté aux données numériques continues. Paramètres : `n_init=10`, `random_state=42`.
4. **Choix de** k : méthode du coude (*Elbow Method*) sur le WCSS pour $k \in [2, 15]$. Le coude observé suggère $k = 6$.

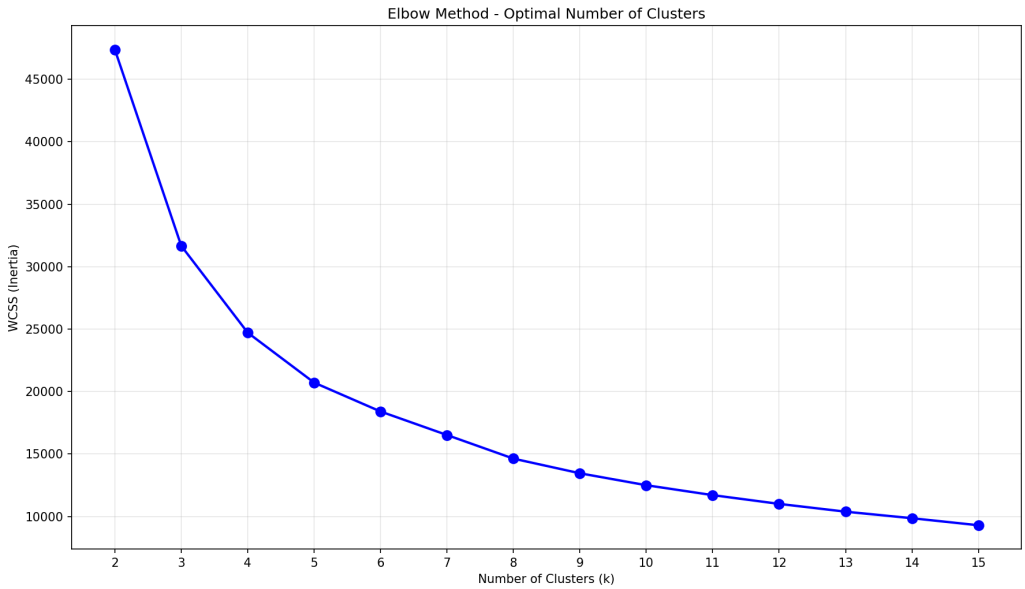

FIGURE 1 – Méthode du coude – WCSS en fonction de k

3 Résultats

3.1 Distribution des clusters

TABLE 2 – Statistiques par cluster ($k = 6$)

Cluster	Effectif	Prix moyen ($)	Revenu moyen	Zone géographique
0	4 766	213 622	4.20	Sud (LA périphérie)
1	5 294	121 905	2.82	Nord intérieur (Sacramento)
2	584	482 953	10.36	Hauts revenus (dispersés)
3	4 882	126 273	2.45	Sud intérieur (Riverside)
4	3 112	300 859	4.94	Baie de San Francisco
5	2 002	385 234	5.76	Côte sud (LA côtière)

3.2 Visualisation géographique

3.3 Interprétation synthétique

- Le clustering reflète une segmentation **géographique et socio-économique** cohérente de la Californie.
- Les **zones côtières** (clusters 4, 5) présentent des prix et revenus élevés.
- Les **zones intérieures** (clusters 1, 3) regroupent les logements les moins chers et les revenus les plus bas.
- Le **cluster 2** (584 observations) isole une population à très hauts revenus, dispersée sur le territoire.
- Le dataset final, enrichi de la colonne `cluster`, est exporté dans `data/transformed_housing_dat`

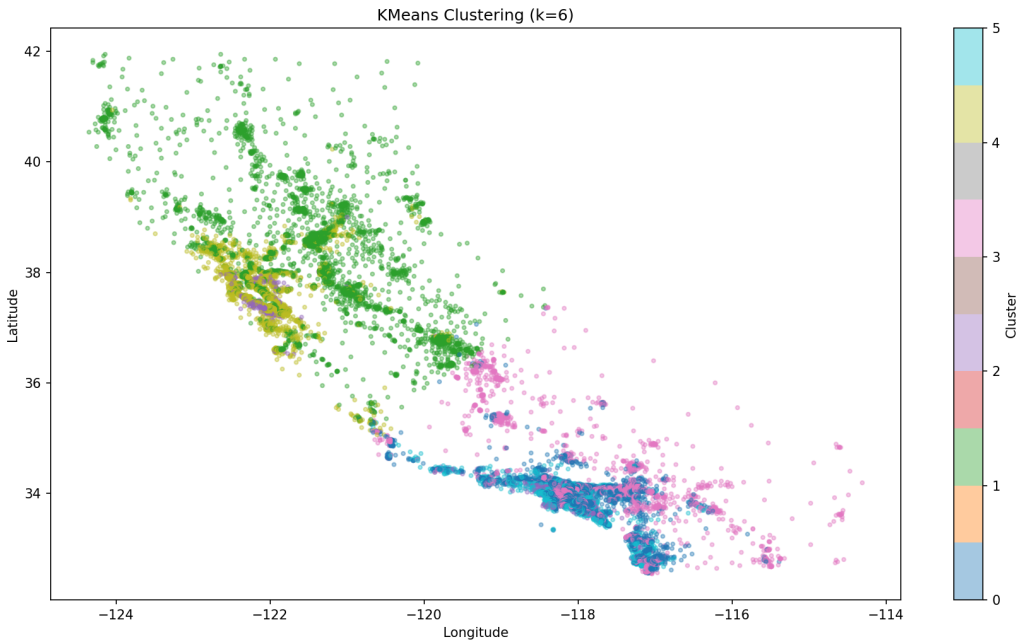

FIGURE 2 – Répartition spatiale des clusters (latitude vs longitude)

4 Pipeline de transformation

1. Chargement de `housing.csv` (20 640 lignes, 10 colonnes)
2. Suppression des lignes avec valeurs manquantes sur les 4 variables de clustering (0 lignes supprimées)
3. Standardisation (`StandardScaler`)
4. KMeans ($k = 6$) $\rightarrow$ ajout de la colonne `cluster`
5. Export $\rightarrow$ `transformed_housing_data.csv` (20 640 lignes, 11 colonnes)