Clustering des données immobilières californiennes

Bloc IA — Prosit 1

25 mars 2026

1 Description des données

Le jeu de données `housing.csv` contient 20 640 enregistrements issus du recensement californien de 1990. Chaque ligne correspond à un *block group* (plus petite unité administrative, 500 à 5 000 habitants).

Table 1 – Variables du dataset

Variable	Type	Description
longitude / latitude	float	Coordonnées géographiques
housing_median_age	float	Âge médian des logements
total_rooms	float	Nombre total de pièces
total_bedrooms	float	Nombre total de chambres
population	float	Population du block group
households	float	Nombre de ménages
median_income	float	Revenu médian (en dizaines de k$)
median_house_value	float	Prix médian du logement ($)
ocean_proximity	cat.	Proximité à l'océan

Valeurs manquantes : seule `total_bedrooms` présentait 207 valeurs nulles. Ces valeurs ont été imputées à l'aide de **KNNImputer** (k=5, pondération par distance) en utilisant l'ensemble des autres variables numériques. Le dataset imputé est exporté dans `data/housing_data_knn.csv`.

2 Choix méthodologiques

1. **Imputation des valeurs manquantes** : KNNImputer (k=5, `weights='distance'`) après standardisation. Chaque valeur manquante de `total_bedrooms` est prédite à partir de ses 5 plus proches voisins complets.
2. **Sélection des variables** : `latitude`, `longitude`, `median_income`, `median_house_value`. Ces variables captent à la fois la position géographique et le profil socio-économique de chaque zone.
3. **Standardisation** : StandardScaler (centrage-réduction) appliqué aux 4 variables afin qu'aucune ne domine le calcul de distance euclidienne.
4. **Algorithme** : KMeans — simple, rapide et bien adapté aux données numériques continues. Paramètres : `n_init=10`, `random_state=42`.
5. **Choix de k** : méthode du coude (Elbow Method) sur le WCSS pour $k \in [2, 15]$. Le coude observé suggère $k = 6$.

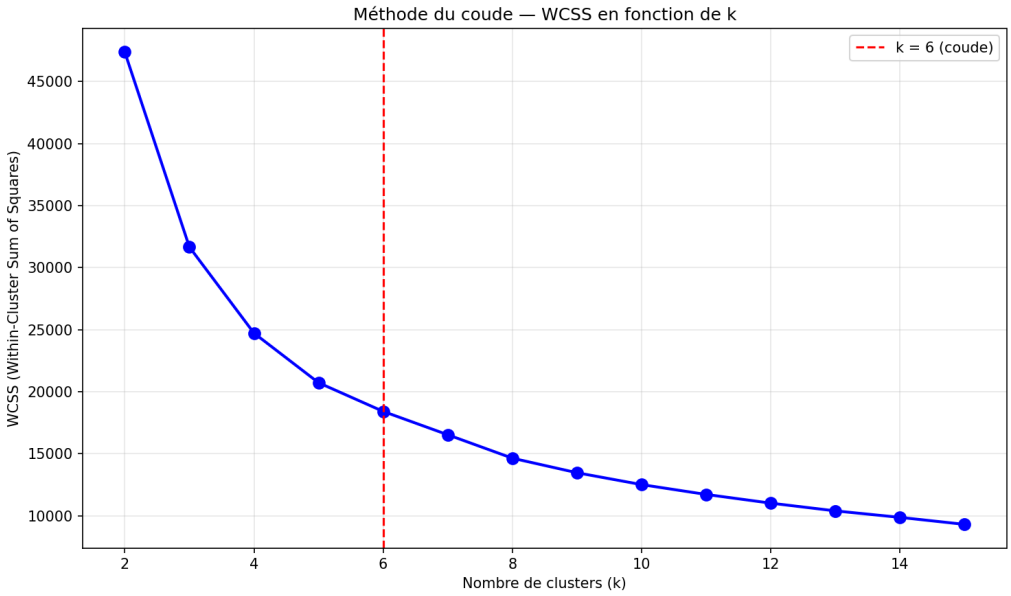

FIGURE 1 – Méthode du coude — WCSS en fonction de k

3 Résultats

3.1 Distribution des clusters

TABLE 2 – Statistiques par cluster (k = 6)

Cluster	Effectif	Prix moyen ($)	Revenu moyen	Zone géographique
0	4 766	213 622	4.20	Sud (LA périphérie)
1	5 294	121 905	2.82	Nord intérieur (Sacramento)
2	584	482 953	10.36	Hauts revenus (dispersés)
3	4 882	126 273	2.45	Sud intérieur (Riverside)
4	3 112	300 859	4.94	Baie de San Francisco
5	2 002	385 234	5.76	Côte sud (LA côtière)

3.2 Visualisation géographique

3.3 Interprétation synthétique

- Le clustering reflète une segmentation géographique et socio-économique cohérente de la Californie.
- Les zones côtières (clusters 4, 5) présentent des prix et revenus élevés.
- Les zones intérieures (clusters 1, 3) regroupent les logements les moins chers et les revenus les plus bas.
- Le cluster 2 (584 observations) isole une population à très hauts revenus, dispersée sur le territoire.
- Le dataset final, enrichi de la colonne `cluster`, est exporté dans `data/housing_data_knn_clustered.csv`

4 Pipeline de transformation

1. Chargement de `housing.csv` (20 640 lignes, 10 colonnes)

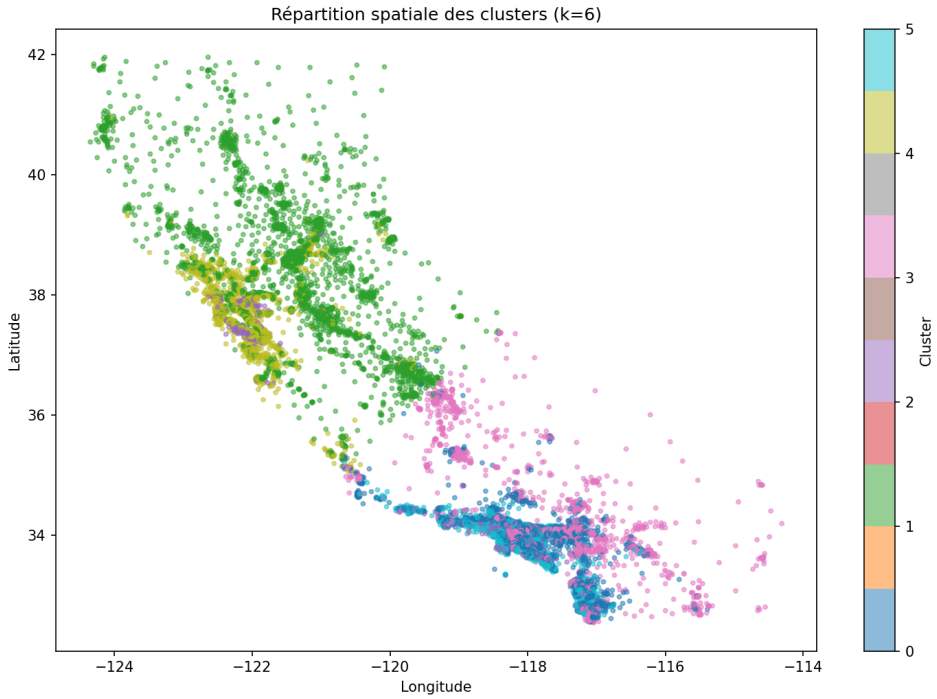

FIGURE 2 – Répartition spatiale des clusters (latitude vs longitude)

2. Imputation de `total_bedrooms` via KNNImputer (k=5) → `housing_data_knn.csv`
3. Sélection des 4 variables de clustering
4. Standardisation (StandardScaler)
5. KMeans ($k = 6$) → ajout de la colonne `cluster`
6. Export → `housing_data_knn_clustered.csv` (20 640 lignes, 11 colonnes)