Clustering des données immobilières californiennes

Bloc IA — Prosit 1

25 mars 2026

Dépôt GitHub : `https://github.com/Anisse-Imer/bloc-ia-prosit-1-clustering`

Table des matières

1 Description des données **2**

2 Choix méthodologiques **2**

3 Résultats **3**
- 3.1 Principe de KMeans . . . 3
- 3.2 Distribution des clusters . . . 4
- 3.3 Visualisation géographique . . . 4
- 3.4 Interprétation synthétique . . . 4

4 Analyse exploratoire et interprétation **5**
- 4.1 Qualité des données — valeurs plafonnées . . . 5
- 4.2 Revenu et prix — la corrélation dominante . . . 5
- 4.3 L'effet côtier . . . 6
- 4.4 Matrice de corrélation . . . 7
- 4.5 Variables dérivées — le ratio chambres/pièces . . . 7
- 4.6 Outliers et données suspectes . . . 8

5 Évaluation du clustering — Analyse Silhouette **8**
- 5.1 Score silhouette en fonction de k . . . 8
- 5.2 Silhouette plot détaillé (k=5) . . . 9
- 5.3 Interprétation . . . 10

6 Pipeline de transformation **10**

1 Description des données

Le jeu de données `housing.csv` contient 20 640 enregistrements issus du recensement californien de 1990. Chaque ligne correspond à un *block group* (plus petite unité administrative, 500 à 5 000 habitants).

Table 1 – Variables du dataset

Variable	Type	Description
longitude / latitude	float	Coordonnées géographiques
housing_median_age	float	Âge médian des logements
total_rooms	float	Nombre total de pièces
total_bedrooms	float	Nombre total de chambres
population	float	Population du block group
households	float	Nombre de ménages
median_income	float	Revenu médian (en dizaines de k$)
median_house_value	float	Prix médian du logement ($)
ocean_proximity	cat.	Proximité à l'océan

Valeurs manquantes : seule `total_bedrooms` présentait 207 valeurs nulles. Ces valeurs ont été imputées à l'aide de **KNNImputer** (k=5, pondération par distance) en utilisant l'ensemble des autres variables numériques. Le dataset imputé est exporté dans `data/housing_data_knn.csv`.

2 Choix méthodologiques

1. **Imputation des valeurs manquantes** : KNNImputer (k=5, `weights='distance'`) après standardisation. Chaque valeur manquante de `total_bedrooms` est prédite à partir de ses 5 plus proches voisins complets.
2. **Variables** : toutes les colonnes du dataset sont utilisées. `ocean_proximity` est encodée via `LabelEncoder` pour la rendre numérique.
3. **Pas de standardisation** : les données brutes sont utilisées directement pour le clustering.
4. **Algorithme** : KMeans — simple, rapide et bien adapté aux données numériques continues. Paramètres : `n_init=10`, `random_state=42`.
5. **Choix de k** : déterminé par **CAH** (Classification Ascendante Hiérarchique, méthode de Ward) via un dendrogramme (figure 1), puis validé par la méthode du coude (Elbow Method) sur le WCSS (figure 2). Les deux approches convergent vers $k = 5$.

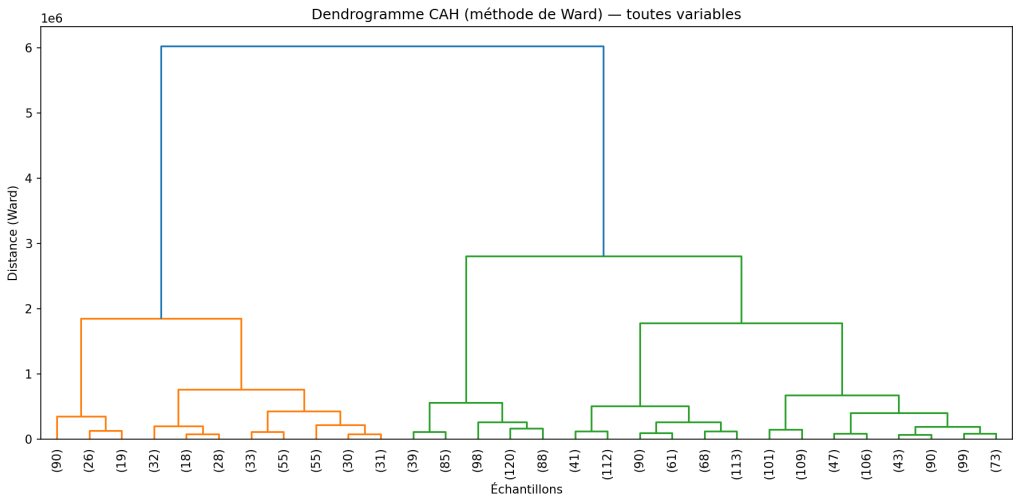

FIGURE 1 – Dendrogramme CAH (méthode de Ward) — échantillon de 2 000 points

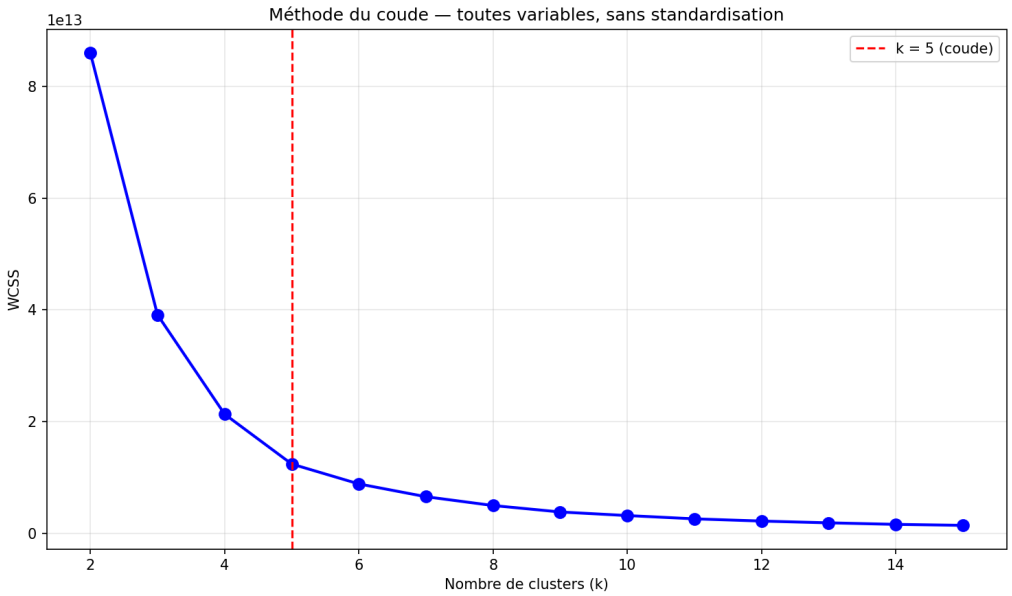

FIGURE 2 – Méthode du coude — WCSS en fonction de k

3 Résultats

3.1 Principe de KMeans

L'algorithme KMeans partitionne les données en k groupes en trois étapes itératives : (1) initialisation aléatoire de k centroïdes, (2) assignation de chaque point au centroïde le plus proche (distance euclidienne), (3) recalcul des centroïdes comme barycentre de chaque groupe. Les étapes 2 et 3 sont répétées jusqu'à convergence (les assignations ne changent plus). L'objectif minimisé est le WCSS (*Within-Cluster Sum of Squares*), soit la somme des distances au carré entre chaque point et son centroïde.

3.2 Distribution des clusters

Table 2 – Statistiques par cluster (k = 5)

Cluster	Effectif	Prix moyen ($)	Revenu moyen
0	5 731	90 084	2.50
1	2 318	346 896	5.24
2	6 446	164 722	3.47
3	1 613	480 484	7.02
4	4 532	245 435	4.35

3.3 Visualisation géographique

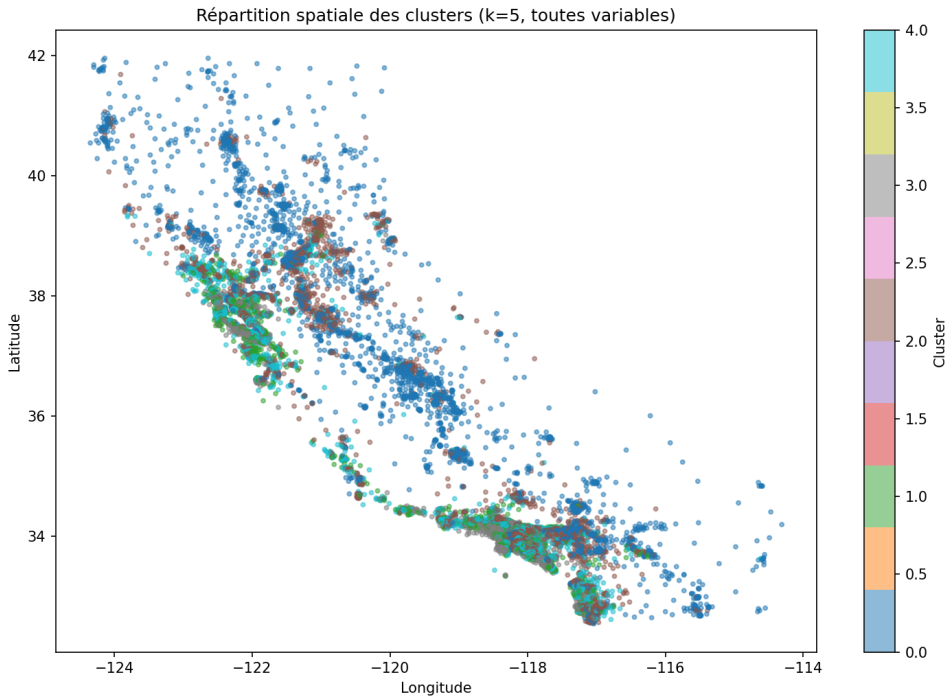

Figure 3 – Répartition spatiale des clusters (latitude vs longitude)

3.4 Interprétation synthétique

- Le clustering segmente la Californie en 5 profils socio-économiques distincts.
- Le **cluster 0** (5 731 block groups) regroupe les zones les moins chères avec les revenus les plus bas — zones rurales et intérieures.
- Le **cluster 3** (1 613 block groups) isole les zones les plus chères avec les revenus les plus élevés (prix moyen 480 484 $, revenu 7.02).
- Les **clusters 1, 2, 4** représentent des profils intermédiaires à différents niveaux de prix et de revenus.
- Le dataset final, enrichi de la colonne `cluster`, est exporté dans `data/housing_data_knn_clustered.csv`

4 Analyse exploratoire et interprétation

4.1 Qualité des données — valeurs plafonnées

Deux variables présentent un **plafonnement artificiel** visible dans leurs distributions (figure 4) :

— `median_house_value` est plafonné à 500 001 $ pour **965 block groups** (4.7 %). Ces zones, probablement les plus chères (Beverly Hills, Palo Alto...), ont leur prix réel tronqué. Cela biaise toute analyse des hauts de gamme et peut fausser le clustering en regroupant artificiellement des zones de prix très différents.

— `housing_median_age` est plafonné à 52 ans pour **1 273 block groups** (6.2 %). Les bâtiments les plus anciens sont donc indistinguables dans le dataset.

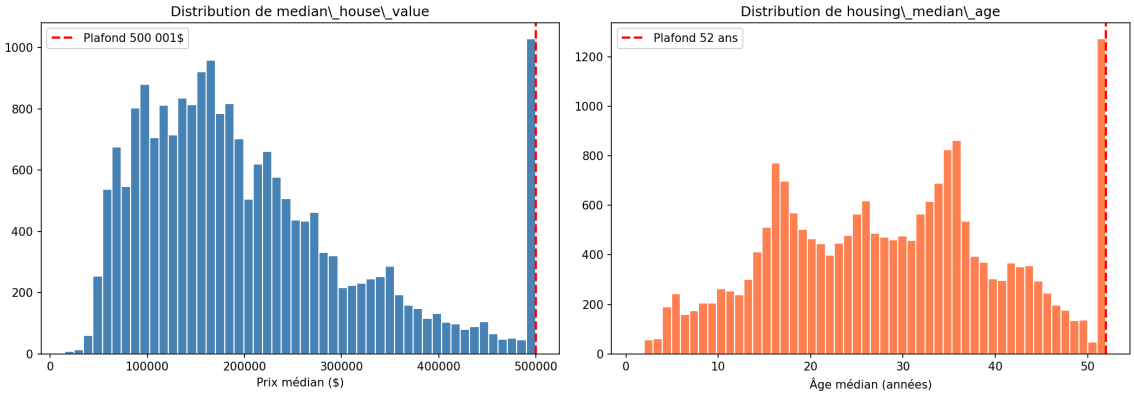

FIGURE 4 – Distributions avec valeurs plafonnées (pics visibles aux bornes)

4.2 Revenu et prix — la corrélation dominante

Le revenu médian est de loin le meilleur prédicteur du prix ($r = 0.69$), bien devant toutes les autres variables. La figure 5 montre cette relation quasi-linéaire, avec deux anomalies notables :

— Une **ligne horizontale à 500 001 $** : les valeurs plafonnées, qui créent un artefact visuel et statistique.

— Des **zones à haut revenu mais prix modéré** (coin bas-droit) : possiblement des zones rurales aisées avec un foncier bon marché.

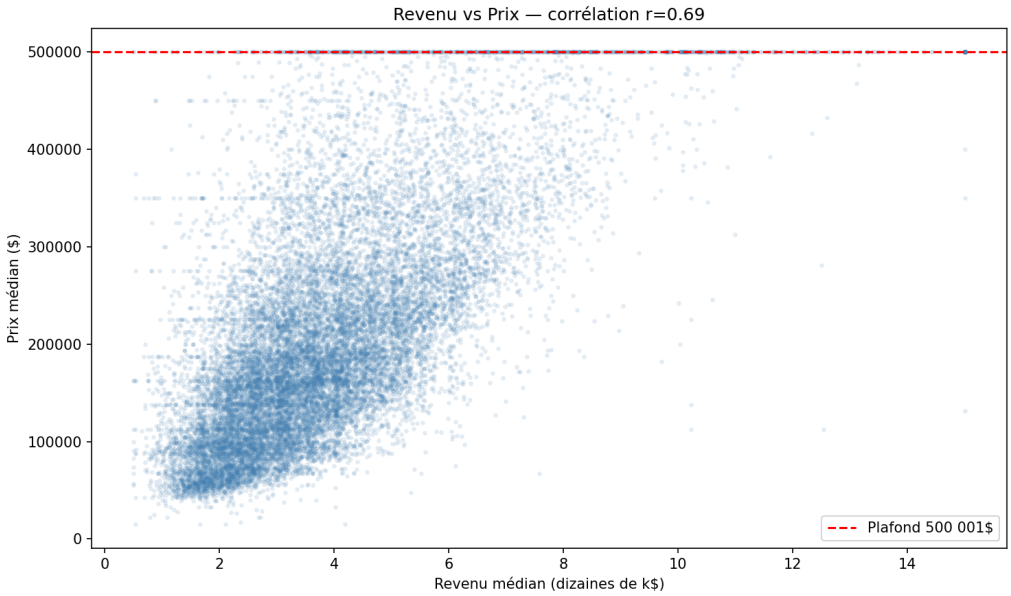

FIGURE 5 – Revenu médian vs prix — corrélation $r = 0.69$

4.3 L'effet côtier

La proximité à l'océan a un impact majeur sur les prix (figure 6). Les zones `INLAND` affichent un prix médian de 108 500 $, contre 233 800 $ pour `NEAR BAY` — plus du double. La catégorie `ISLAND` (5 observations seulement) montre des prix très élevés mais n'est pas statistiquement significative.

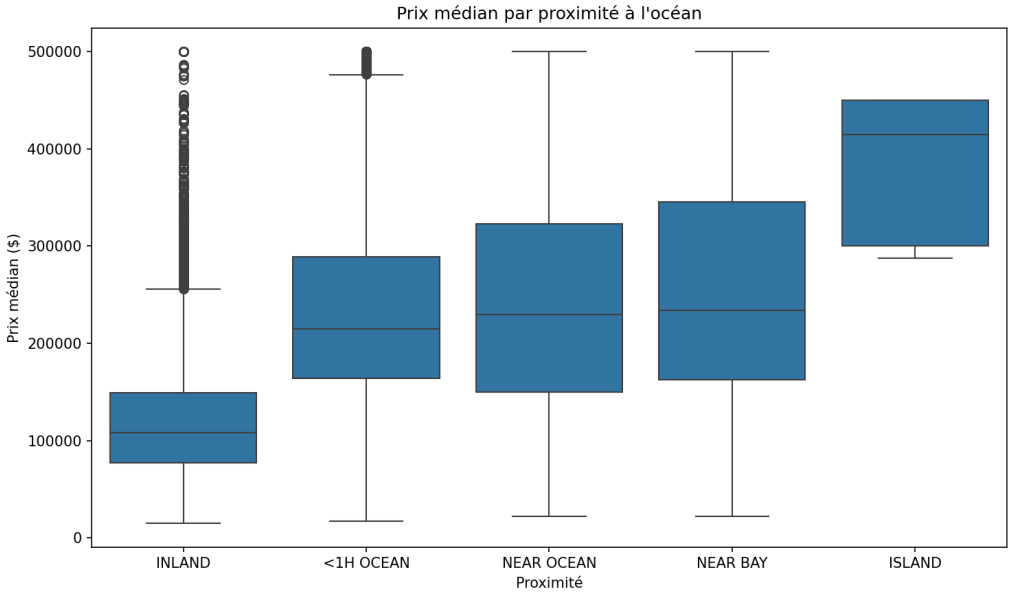

FIGURE 6 – Prix médian par proximité à l'océan

La majorité des block groups (44.3 %) se trouvent à moins d'une heure de l'océan, et près d'un tiers (31.7 %) sont situés en zone intérieure.

Ce déséquilibre explique en partie la structure du clustering. La Californie est un État profondément dual : une frange côtière densément peuplée et chère, et un vaste intérieur agricole et résidentiel à prix modéré. La variable `ocean_proximity` est intégrée au clustering via un enco-

dage `LabelEncoder`, ce qui permet au modèle de capter directement cette dimension côtière en complément des coordonnées géographiques.

4.4 Matrice de corrélation

La figure 7 révèle plusieurs structures intéressantes :

— `total_rooms`, `total_bedrooms`, `population` et `households` sont fortement corrélés entre eux ($r > 0.85$). Ce sont des mesures de **taille du block group** : un quartier plus peuplé a logiquement plus de pièces, de chambres et de ménages. Utiliser ces 4 variables simultanément dans un modèle introduirait de la **multicolinéarité**.

— `latitude` et `longitude` captent la géographie : les prix baissent quand on s'éloigne de la côte (latitude élevée = nord, corrélation négative avec le prix).

— `median_income` est la seule variable fortement corrélée au prix ($r = 0.69$) sans être redondante avec les autres.

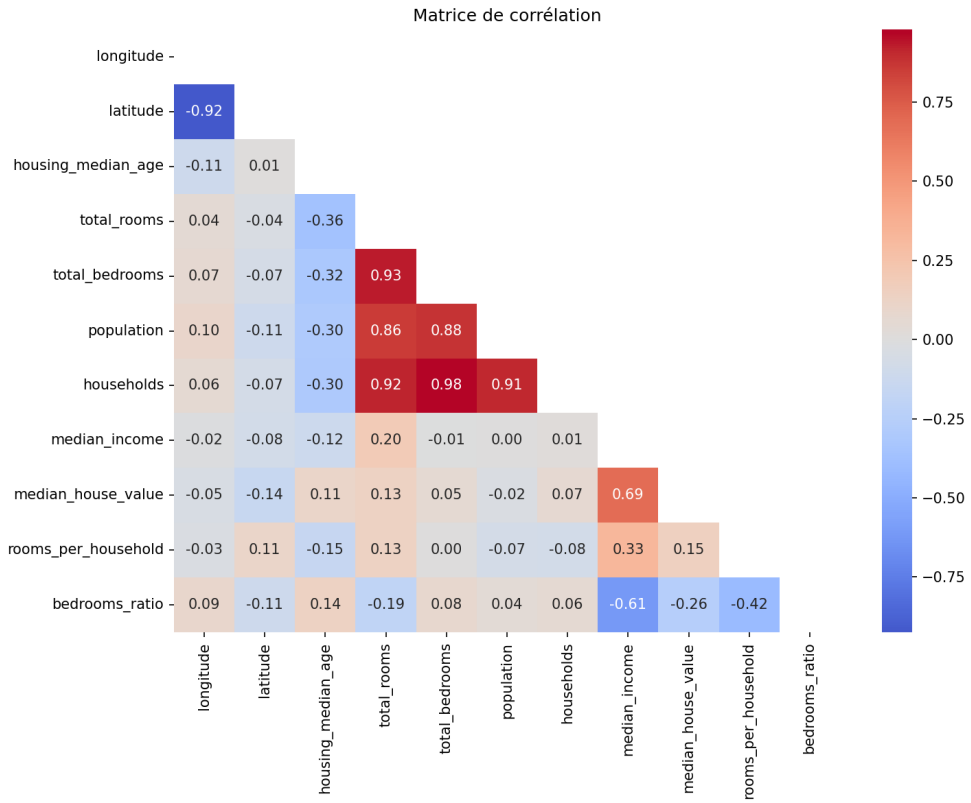

FIGURE 7 – Matrice de corrélation des variables numériques

Malgré la multicolinéarité entre les variables de taille, toutes les variables sont conservées dans le clustering. Sans standardisation, ce sont les variables à grande échelle (`median_house_value`, `total_rooms`, `population`) qui dominent naturellement le calcul de distance euclidienne, ce qui oriente le clustering vers une segmentation principalement économique et démographique.

4.5 Variables dérivées — le ratio chambres/pièces

En créant le ratio `bedrooms_ratio` = `total_bedrooms` / `total_rooms`, on obtient une corrélation négative avec le prix ($r = -0.26$). Les logements avec une **proportion élevée de chambres** par rapport au nombre total de pièces sont moins chers. Cela correspond à des logements plus petits (studios, T1) où la chambre constitue l'essentiel de l'espace, typiques des zones à faible revenu.

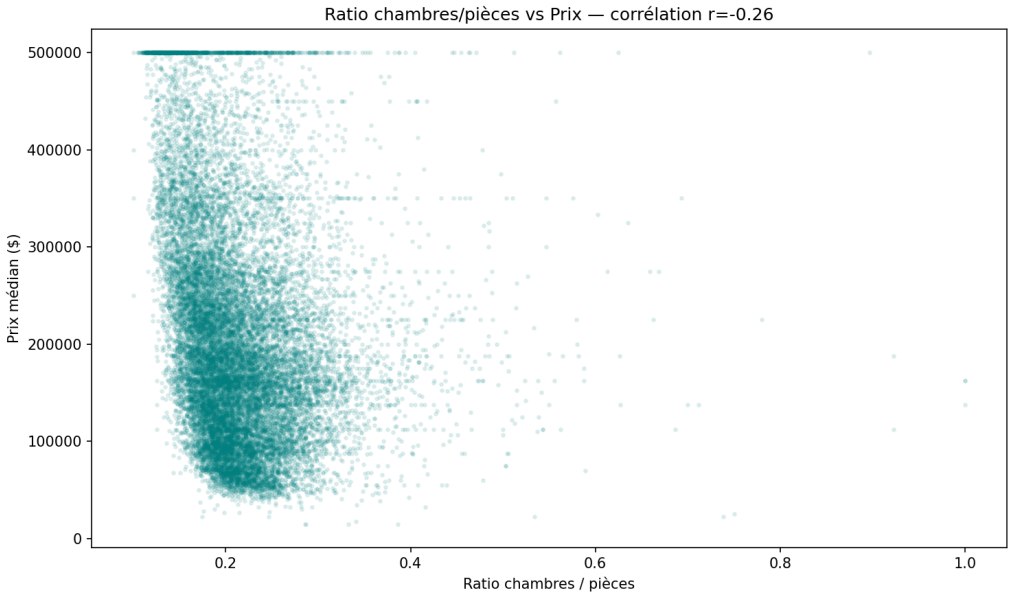

FIGURE 8 – Ratio chambres/pièces vs prix — corrélation $r = -0.26$

À l'inverse, un ratio faible signale des logements spacieux avec salon, bureau, salle à manger — typiques des quartiers résidentiels aisés. Cette variable dérivée est plus informative que `total_bedrooms` seul ($r = 0.05$ avec le prix) car elle normalise par la taille du logement et capture réellement la **structure** du bien plutôt que sa taille brute. Dans un modèle prédictif, ce ratio serait un candidat pertinent en remplacement des variables brutes `total_rooms` et `total_bedrooms`.

4.6 Outliers et données suspectes

Quelques observations extrêmes méritent attention :

- **33 block groups** ont plus de 20 000 pièces totales, et **9** ont plus de 50 pièces par ménage. Ces valeurs sont physiquement improbables et pourraient résulter d'erreurs de saisie ou de block groups atypiques (résidences universitaires, casernes).
- **23 block groups** dépassent 10 000 habitants, avec un maximum à 35 682 — inhabituellement élevé pour la plus petite division administrative.
- Le ratio `population_per_household` atteint 1 243 pour un block group, ce qui est manifestement une erreur (moyenne = 3.07).

Ces anomalies n'ont pas été filtrées dans le pipeline actuel mais devraient l'être dans un contexte de modélisation prédictive.

5 Évaluation du clustering — Analyse Silhouette

Le score silhouette mesure pour chaque point la qualité de son assignation : $s = (b - a)/\max(a, b)$, où a est la distance moyenne aux points de son propre cluster et b la distance moyenne aux points du cluster le plus proche. Un score de $+1$ indique un point parfaitement classé, 0 un point à la frontière, et un score négatif un point probablement mal assigné.

5.1 Score silhouette en fonction de k

La figure 9 montre l'évolution du score silhouette moyen pour $k \in [2, 10]$. Le choix de $k = 5$ offre un compromis entre granularité de la segmentation et qualité du clustering.

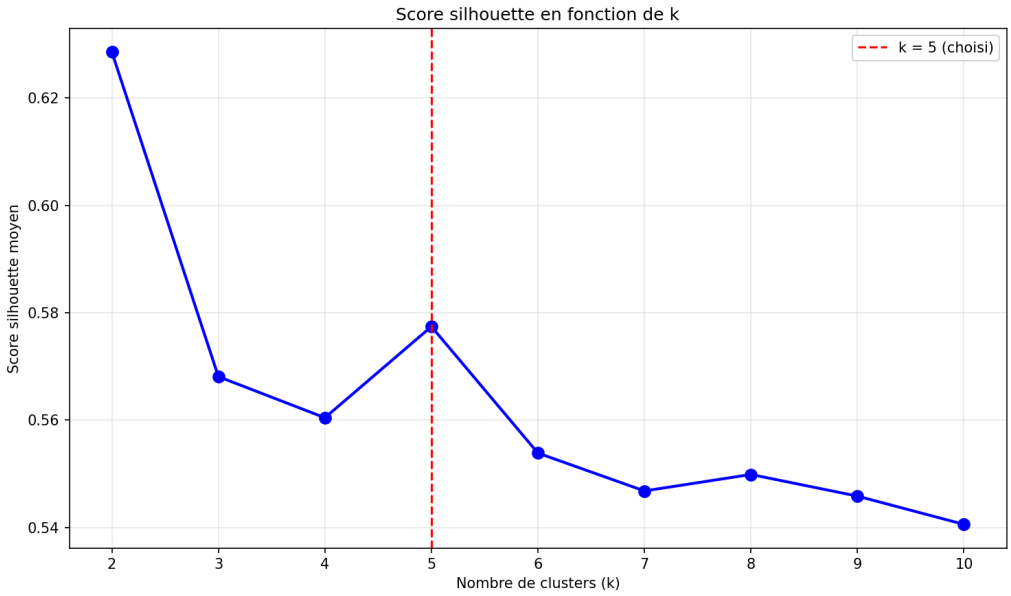

FIGURE 9 – Score silhouette moyen en fonction de k

5.2 Silhouette plot détaillé (k=5)

La figure 10 détaille la distribution du score silhouette pour chaque cluster. L'analyse silhouette doit être re-exécutée avec les nouveaux paramètres ($k = 5$, toutes variables, sans standardisation) via le notebook `silhouette_analysis.ipynb`.

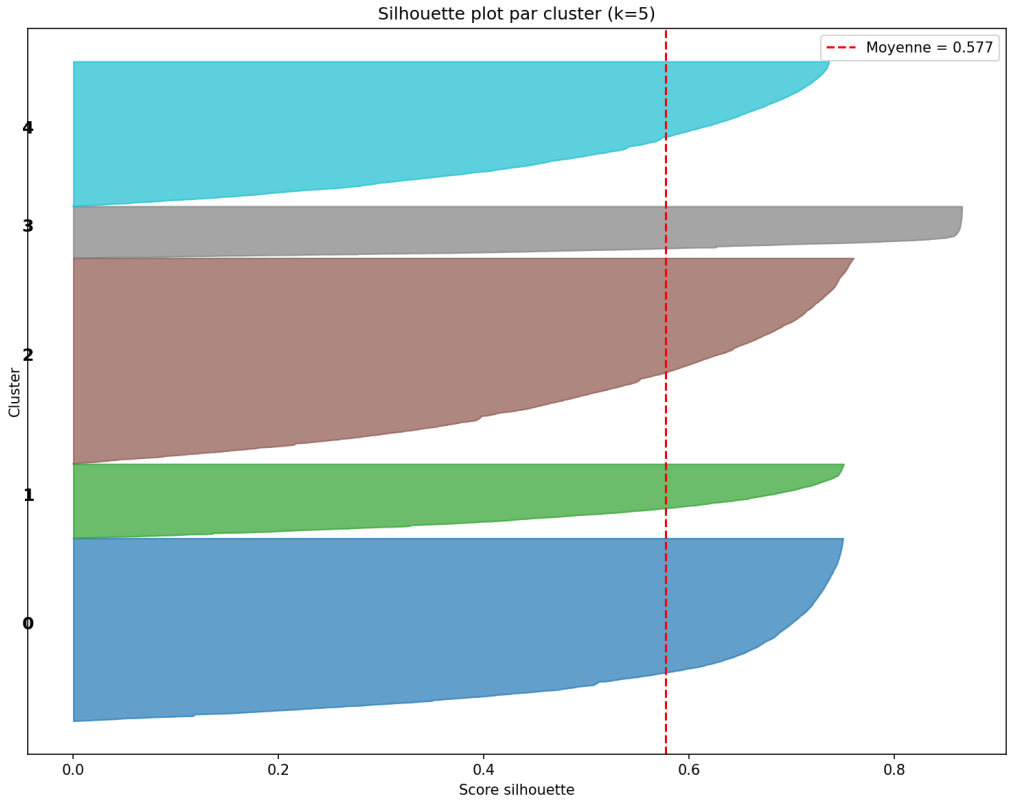

FIGURE 10 – Silhouette plot par cluster (k=5)

5.3 Interprétation

Le score silhouette permet d'identifier les clusters les plus cohérents (score élevé, peu de points négatifs) et les plus fragiles (score faible, proportion importante de points mal assignés). Les clusters à score négatif élevé indiquent des zones de transition entre segments, ce qui est attendu dans un espace géographique continu.

6 Pipeline de transformation

1. Chargement de `housing.csv` (20 640 lignes, 10 colonnes)
2. Imputation de `total_bedrooms` via KNNImputer (k=5) → `housing_data_knn.csv`
3. Encodage de `ocean_proximity` via `LabelEncoder`
4. Détermination de k par CAH (dendrogramme de Ward)
5. Validation par méthode du coude (WCSS) → $k = 5$
6. KMeans ($k = 5$) sur toutes les variables → ajout de la colonne `cluster`
7. Export → `housing_data_knn_clustered.csv` (20 640 lignes, 11 colonnes)

Glossaire

Algorithme des K-Means Algorithme de clustering partitionnant les données en k groupes en minimisant la somme des distances intra-cluster (WCSS). Itératif : assignation puis mise à jour des centroïdes.

Analyse Processus d'examen méthodique des données pour en dégager des tendances, des structures ou des anomalies.

Apprentissage automatique (*Machine Learning*) Sous-domaine de l'IA où les algorithmes apprennent des patterns à partir de données sans être explicitement programmés.

Apprentissage supervisé / non-supervisé Supervisé : le modèle apprend à partir d'exemples étiquetés (classification, régression). Non-supervisé : le modèle découvre des structures sans étiquettes (clustering, réduction de dimension). KMeans est non-supervisé.

Archive .tgz Format de fichier compressé (*tar* + *gzip*) couramment utilisé pour distribuer des jeux de données.

Carte de chaleur (*Heatmap*) Visualisation matricielle où l'intensité de la couleur représente la valeur d'une variable. Utilisée ici pour la matrice de corrélation et la densité géographique.

Classification Ascendante Hiérarchique (CAH) Algorithme de clustering agglomératif construisant un arbre (dendrogramme) en fusionnant itérativement les clusters les plus proches. La méthode de Ward minimise la variance intra-cluster.

CNIL Commission Nationale de l'Informatique et des Libertés. Autorité française chargée de veiller au respect de la protection des données personnelles (RGPD).

Colonnes catégorielles/numériques Variables qualitatives (catégories : `ocean_proximity`) vs quantitatives (nombres : `median_income`). Le traitement diffère selon le type.

Corrélation Mesure de la relation linéaire entre deux variables. Le coefficient de Pearson r varie de -1 (inverse) à $+1$ (directe), 0 = aucune relation linéaire.

Distribution des variables Répartition statistique des valeurs d'une variable, caractérisée par sa forme (normale, asymétrique), sa tendance centrale et sa dispersion.

Éthique Ensemble de principes guidant l'utilisation responsable de l'IA et des données : transparence, équité, respect de la vie privée, non-discrimination.

Exploité Qualifie un jeu de données qui a été traité, nettoyé et analysé pour en extraire de l'information utile.

Gestion des valeurs manquantes Ensemble de techniques pour traiter les données absentes : suppression, imputation par médiane, KNN, etc.

Histogramme Graphique en barres montrant la distribution de fréquence d'une variable continue, découpée en intervalles (*bins*).

Imputation Remplacement des valeurs manquantes par des valeurs estimées. Méthodes : médiane, moyenne, KNNImputer, MICE, etc.

Intelligence artificielle Domaine de l'informatique visant à créer des systèmes capables de simuler des capacités cognitives humaines (raisonnement, apprentissage, prise de décision).

Jeu de données Ensemble structuré de données utilisé pour l'analyse ou l'entraînement d'un modèle. Ici : `housing.csv` (20 640 lignes, 10 colonnes).

Lisibilité des données et graphiques Qualité d'une représentation qui permet une interprétation rapide et correcte (choix des échelles, couleurs, légendes).

Modèle d'apprentissage automatique Algorithme entraîné sur des données pour effectuer des prédictions ou des classifications. Exemples : régression, KMeans, arbres de décision.

Optimiser Améliorer les performances d'un modèle ou d'un processus en ajustant ses paramètres ou sa structure.

Pandas Bibliothèque Python pour la manipulation et l'analyse de données tabulaires via les structures `DataFrame` et `Series`.

Standardisation et normalisation Standardisation (*z-score*) : centrage-réduction ($\mu = 0, \sigma = 1$). Normalisation (*min-max*) : mise à l'échelle $[0, 1]$. Utilisées pour homogénéiser les échelles des variables avant un algorithme basé sur les distances.

Statistiques descriptives Mesures résumant un jeu de données : moyenne, médiane, écart-type, quartiles, min/max.

Type de données Nature d'une variable : numérique (float, int) ou catégorielle (chaîne de caractères). Détermine les traitements applicables.

Valeur médiane Valeur séparant un ensemble de données en deux moitiés égales. Plus robuste aux outliers que la moyenne.

Visualisation Représentation graphique des données (histogrammes, scatter plots, cartes de chaleur) pour faciliter leur compréhension.

Visualisation spatiale Représentation de données géolocalisées sur une carte ou un plan (scatter plot lat/lon, Folium, Plotly maps).

Zone géographique Région délimitée par des coordonnées spatiales. Dans ce projet, chaque *block group* californien est localisé par sa latitude et sa longitude.

Zone homogène Ensemble de points partageant des caractéristiques similaires. Un cluster est une zone homogène dans l'espace des variables.