Clustering des données immobilières californiennes

Bloc IA — Prosit 1

25 mars 2026

1 Description des données

Le jeu de données `housing.csv` contient 20 640 enregistrements issus du recensement californien de 1990. Chaque ligne correspond à un *block group* (plus petite unité administrative, 500 à 5 000 habitants).

Table 1 – Variables du dataset

Variable	Type	Description
longitude / latitude	float	Coordonnées géographiques
housing_median_age	float	Âge médian des logements
total_rooms	float	Nombre total de pièces
total_bedrooms	float	Nombre total de chambres
population	float	Population du block group
households	float	Nombre de ménages
median_income	float	Revenu médian (en dizaines de k$)
median_house_value	float	Prix médian du logement ($)
ocean_proximity	cat.	Proximité à l'océan

Valeurs manquantes : seule `total_bedrooms` présentait 207 valeurs nulles. Ces valeurs ont été imputées à l'aide de **KNNImputer** (k=5, pondération par distance) en utilisant l'ensemble des autres variables numériques. Le dataset imputé est exporté dans `data/housing_data_knn.csv`.

2 Choix méthodologiques

1. **Imputation des valeurs manquantes** : KNNImputer (k=5, `weights='distance'`) après standardisation. Chaque valeur manquante de `total_bedrooms` est prédite à partir de ses 5 plus proches voisins complets.
2. **Sélection des variables** : `latitude`, `longitude`, `median_income`, `median_house_value`. Ces variables captent à la fois la position géographique et le profil socio-économique de chaque zone.
3. **Standardisation** : StandardScaler (centrage-réduction) appliqué aux 4 variables afin qu'aucune ne domine le calcul de distance euclidienne.
4. **Algorithme** : KMeans — simple, rapide et bien adapté aux données numériques continues. Paramètres : `n_init=10`, `random_state=42`.
5. **Choix de k** : méthode du coude (Elbow Method) sur le WCSS pour $k \in [2, 15]$. Le coude observé suggère $k = 6$.

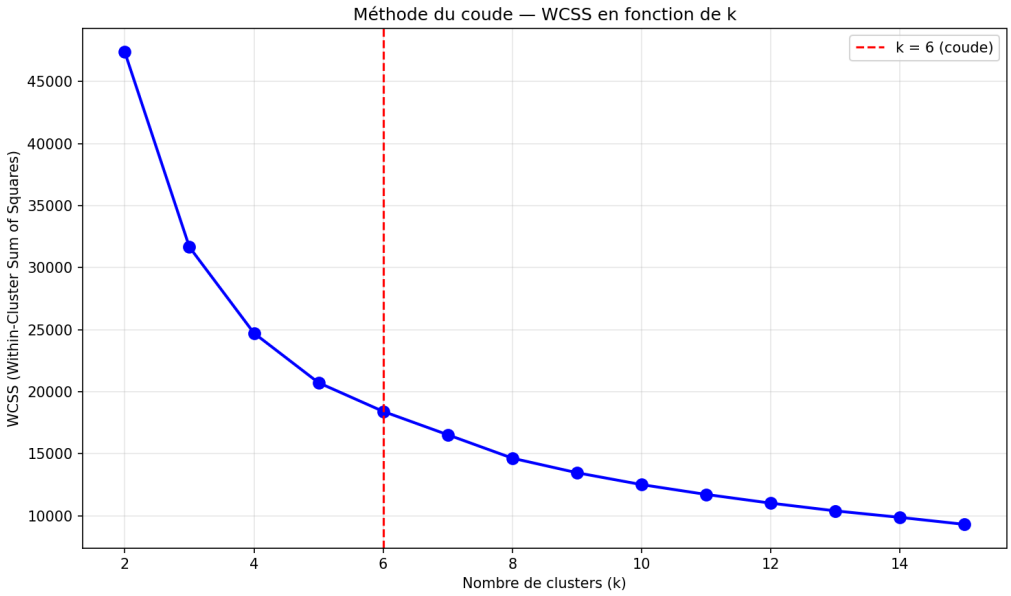

FIGURE 1 – Méthode du coude — WCSS en fonction de k

3 Résultats

3.1 Distribution des clusters

TABLE 2 – Statistiques par cluster (k = 6)

Cluster	Effectif	Prix moyen ($)	Revenu moyen	Zone géographique
0	4 766	213 622	4.20	Sud (LA périphérie)
1	5 294	121 905	2.82	Nord intérieur (Sacramento)
2	584	482 953	10.36	Hauts revenus (dispersés)
3	4 882	126 273	2.45	Sud intérieur (Riverside)
4	3 112	300 859	4.94	Baie de San Francisco
5	2 002	385 234	5.76	Côte sud (LA côtière)

3.2 Visualisation géographique

3.3 Interprétation synthétique

- Le clustering reflète une segmentation géographique et socio-économique cohérente de la Californie.
- Les zones côtières (clusters 4, 5) présentent des prix et revenus élevés.
- Les zones intérieures (clusters 1, 3) regroupent les logements les moins chers et les revenus les plus bas.
- Le cluster 2 (584 observations) isole une population à très hauts revenus, dispersée sur le territoire.
- Le dataset final, enrichi de la colonne `cluster`, est exporté dans `data/housing_data_knn_clustered.csv`

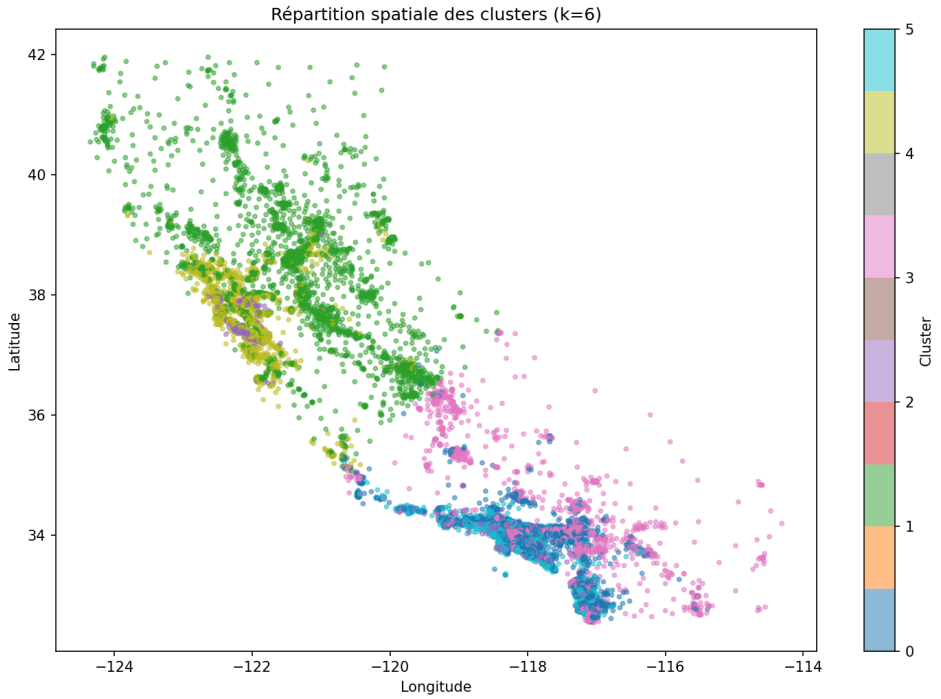

FIGURE 2 – Répartition spatiale des clusters (latitude vs longitude)

4 Analyse exploratoire et interprétation

4.1 Qualité des données — valeurs plafonnées

Deux variables présentent un **plafonnement artificiel** visible dans leurs distributions (figure 3) :

— `median_house_value` est plafonné à 500 001 $ pour **965 block groups** (4.7 %). Ces zones, probablement les plus chères (Beverly Hills, Palo Alto...), ont leur prix réel tronqué. Cela biaise toute analyse des hauts de gamme et peut fausser le clustering en regroupant artificiellement des zones de prix très différents.

— `housing_median_age` est plafonné à 52 ans pour **1 273 block groups** (6.2 %). Les bâtiments les plus anciens sont donc indistinguables dans le dataset.

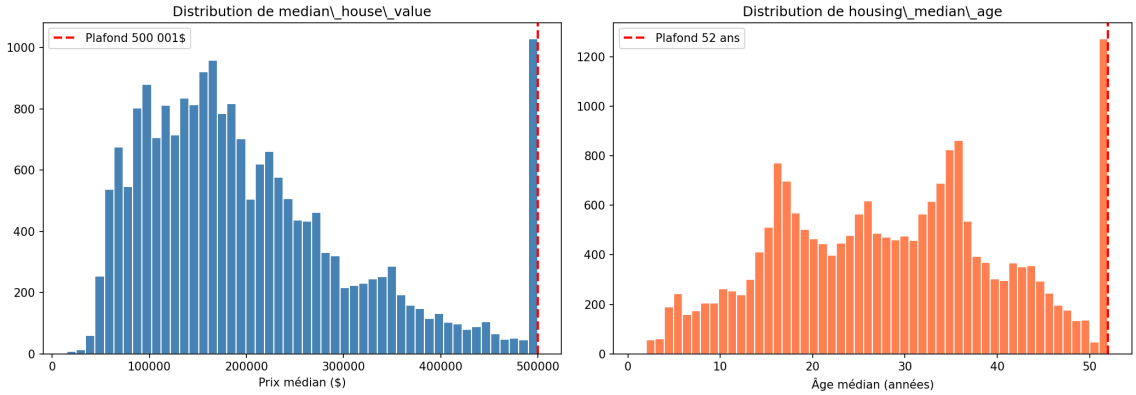

FIGURE 3 – Distributions avec valeurs plafonnées (pics visibles aux bornes)

4.2 Revenu et prix — la corrélation dominante

Le revenu médian est de loin le meilleur prédicteur du prix ($r = 0.69$), bien devant toutes les autres variables. La figure 4 montre cette relation quasi-linéaire, avec deux anomalies notables :

— Une **ligne horizontale à 500 001 $** : les valeurs plafonnées, qui créent un artefact visuel et statistique.

— Des **zones à haut revenu mais prix modéré** (coin bas-droit) : possiblement des zones rurales aisées avec un foncier bon marché.

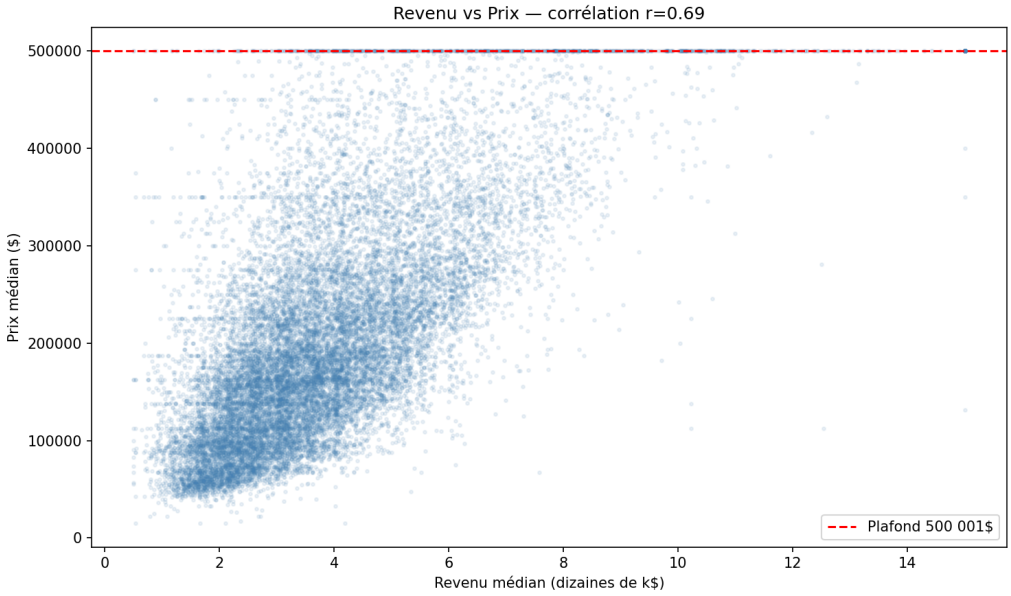

FIGURE 4 – Revenu médian vs prix — corrélation $r = 0.69$

4.3 L'effet côtier

La proximité à l'océan a un impact majeur sur les prix (figure 5). Les zones `INLAND` affichent un prix médian de 108 500 $, contre 233 800 $ pour `NEAR BAY` — plus du double. La catégorie `ISLAND` (5 observations seulement) montre des prix très élevés mais n'est pas statistiquement significative.

La majorité des block groups (44.3 %) se trouvent à moins d'une heure de l'océan, et près d'un tiers (31.7 %) sont situés en zone intérieure.

Ce déséquilibre explique en partie la structure du clustering : les clusters 1 et 3, qui regroupent les zones intérieures à bas prix, totalisent 10 176 block groups (49 % du dataset). La Californie est un État profondément dual : une frange côtière densément peuplée et chère, et un vaste intérieur agricole et résidentiel à prix modéré. La variable `ocean_proximity` n'est pas utilisée directement dans le clustering (variable catégorielle), mais son effet est capté indirectement par les coordonnées géographiques.

4.4 Matrice de corrélation

La figure 6 révèle plusieurs structures intéressantes :

— `total_rooms`, `total_bedrooms`, `population` et `households` sont fortement corrélés entre eux ($r > 0.85$). Ce sont des mesures de **taille du block group** : un quartier plus peuplé a logiquement plus de pièces, de chambres et de ménages. Utiliser ces 4 variables simultanément dans un modèle introduirait de la **multicolinéarité**.

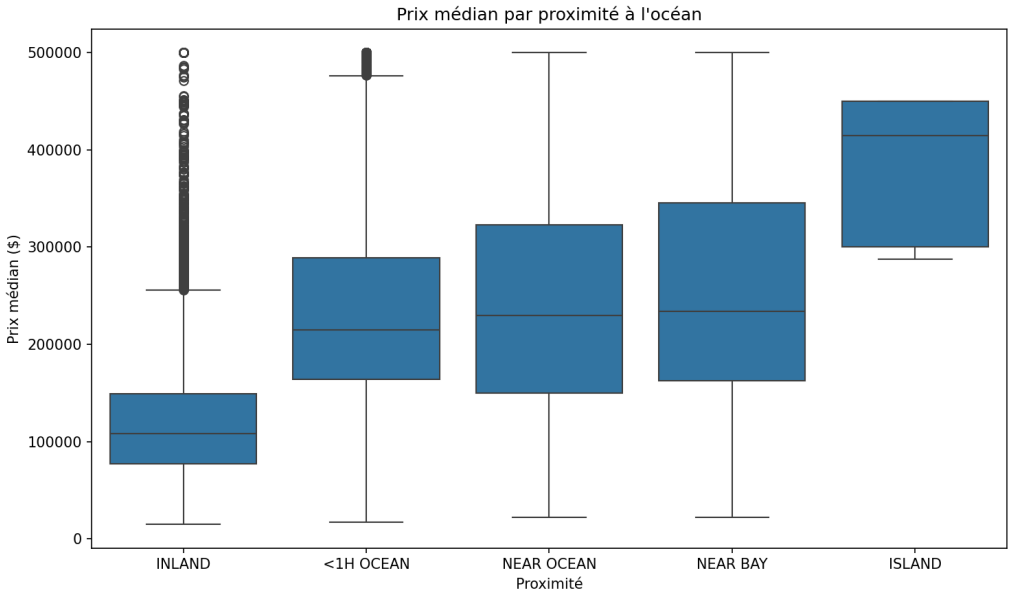

FIGURE 5 – Prix médian par proximité à l'océan

— `latitude` et `longitude` captent la géographie : les prix baissent quand on s'éloigne de la côte (latitude élevée = nord, corrélation négative avec le prix).
— `median_income` est la seule variable fortement corrélée au prix ($r = 0.69$) sans être redondante avec les autres.

Ce résultat justifie le choix des 4 variables de clustering : en excluant les variables de taille (`total_rooms`, `total_bedrooms`, `population`, `households`) qui mesurent toutes la même chose, on évite la redondance. Le couple (`latitude`, `longitude`) apporte la dimension spatiale, tandis que `median_income` est le meilleur proxy du niveau socio-économique — plus discriminant que le prix lui-même, qui est plafonné. On note aussi que `housing_median_age` ne corrèle quasiment avec rien ($r = 0.11$ avec le prix), ce qui confirme son exclusion du clustering.

4.5 Variables dérivées — le ratio chambres/pièces

En créant le ratio `bedrooms_ratio` = `total_bedrooms` / `total_rooms`, on obtient une corrélation négative avec le prix ($r = -0.26$). Les logements avec une **proportion élevée de chambres** par rapport au nombre total de pièces sont moins chers. Cela correspond à des logements plus petits (studios, T1) où la chambre constitue l'essentiel de l'espace, typiques des zones à faible revenu.

À l'inverse, un ratio faible signale des logements spacieux avec salon, bureau, salle à manger — typiques des quartiers résidentiels aisés. Cette variable dérivée est plus informative que `total_bedrooms` seul ($r = 0.05$ avec le prix) car elle normalise par la taille du logement et capture réellement la **structure** du bien plutôt que sa taille brute. Dans un modèle prédictif, ce ratio serait un candidat pertinent en remplacement des variables brutes `total_rooms` et `total_bedrooms`.

4.6 Outliers et données suspectes

Quelques observations extrêmes méritent attention :
— **33 block groups** ont plus de 20 000 pièces totales, et **9** ont plus de 50 pièces par ménage. Ces valeurs sont physiquement improbables et pourraient résulter d'erreurs de saisie ou de block groups atypiques (résidences universitaires, casernes).

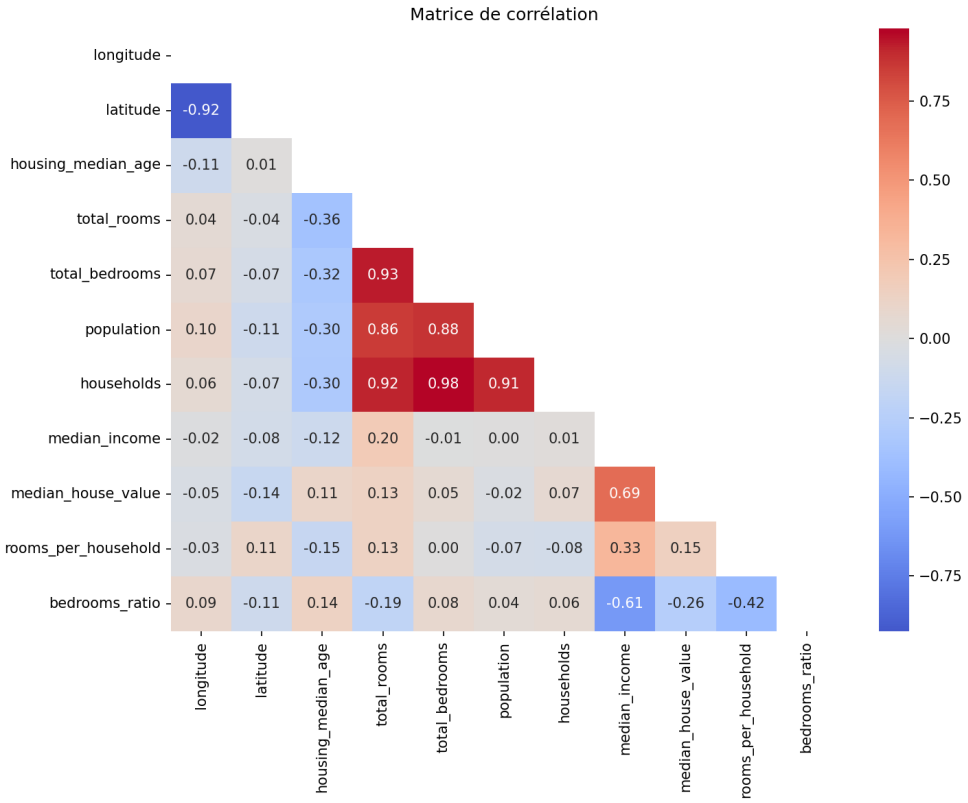

FIGURE 6 – Matrice de corrélation des variables numériques

— **23 block groups** dépassent 10 000 habitants, avec un maximum à 35 682 — inhabituellement élevé pour la plus petite division administrative.
— Le ratio `population_per_household` atteint 1 243 pour un block group, ce qui est manifestement une erreur (moyenne = 3.07).

Ces anomalies n'ont pas été filtrées dans le pipeline actuel mais devraient l'être dans un contexte de modélisation prédictive.

5 Évaluation du clustering — Analyse Silhouette

Le score silhouette mesure pour chaque point la qualité de son assignation : $s = (b - a)/\max(a, b)$, où a est la distance moyenne aux points de son propre cluster et b la distance moyenne aux points du cluster le plus proche. Un score de $+1$ indique un point parfaitement classé, 0 un point à la frontière, et un score négatif un point probablement mal assigné.

5.1 Score silhouette en fonction de k

La figure 8 montre l'évolution du score silhouette moyen pour $k \in [2, 10]$. Le score est maximal pour $k = 3$ ($s = 0.453$) et décroît ensuite. Pour $k = 6$, le score est de $s = 0.326$, ce qui indique une structure de clustering **faible mais existante**. Ce compromis est acceptable : un k plus faible donnerait un meilleur score silhouette mais une segmentation géographique trop grossière pour être utile.

5.2 Silhouette plot détaillé (k=6)

La figure 9 détaille la distribution du score silhouette pour chaque cluster :

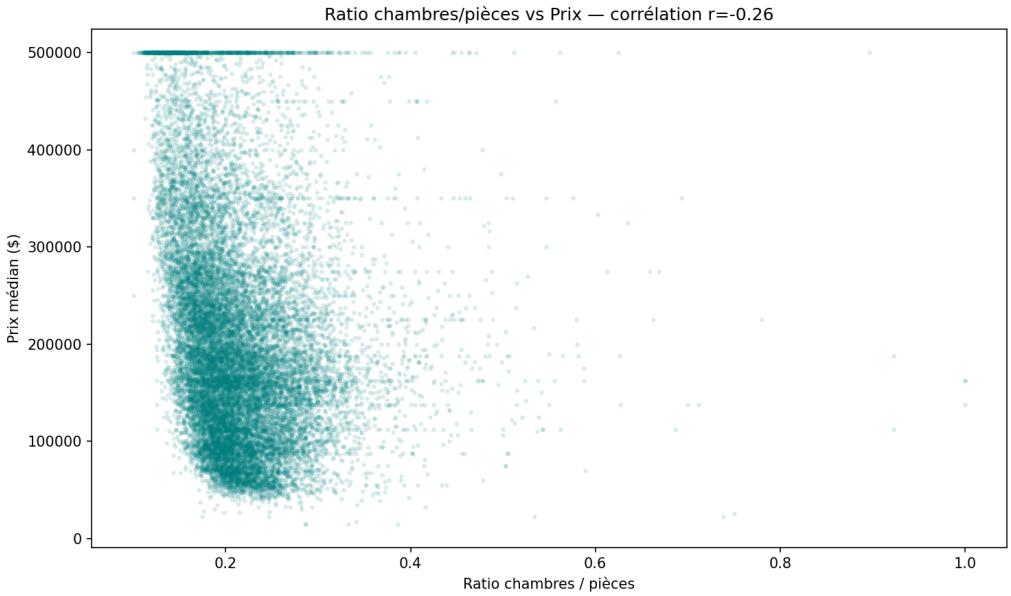

FIGURE 7 – Ratio chambres/pièces vs prix — corrélation $r = -0.26$

TABLE 3 – Statistiques silhouette par cluster

Cluster	Effectif	Silhouette moy.	Silhouette min.	% négatif
0	4 766	0.298	−0.006	0.1 %
1	5 294	0.377	−0.039	1.6 %
2	584	0.246	−0.169	12.8 %
3	4 882	0.312	−0.018	0.6 %
4	3 112	0.361	−0.070	0.7 %
5	2 002	0.264	−0.125	8.7 %

5.3 Interprétation

— Les **clusters 1 et 4** sont les plus cohérents (silhouette > 0.35, très peu de scores négatifs). Ces clusters correspondent aux zones géographiquement et économiquement les plus homogènes : le nord intérieur (Sacramento) et la baie de San Francisco.

— Le **cluster 2** (hauts revenus dispersés) est le plus fragile : 12.8 % de ses points ont un score négatif. Ce résultat est cohérent avec sa nature — ces ménages aisés sont géographiquement dispersés, ce qui affaiblit la cohésion spatiale du cluster.

— Le **cluster 5** (côte sud LA) présente aussi une proportion notable de scores négatifs (8.7 %), ce qui suggère une zone de transition entre les clusters côtiers et intérieurs de Los Angeles.

— Globalement, le faible taux de scores négatifs (< 2 % pour 4 clusters sur 6) confirme que la majorité des points sont raisonnablement bien assignés, même si la séparation entre clusters n'est pas tranchée.

6 Pipeline de transformation

1. Chargement de `housing.csv` (20 640 lignes, 10 colonnes)
2. Imputation de `total_bedrooms` via KNNImputer (k=5) → `housing_data_knn.csv`
3. Sélection des 4 variables de clustering

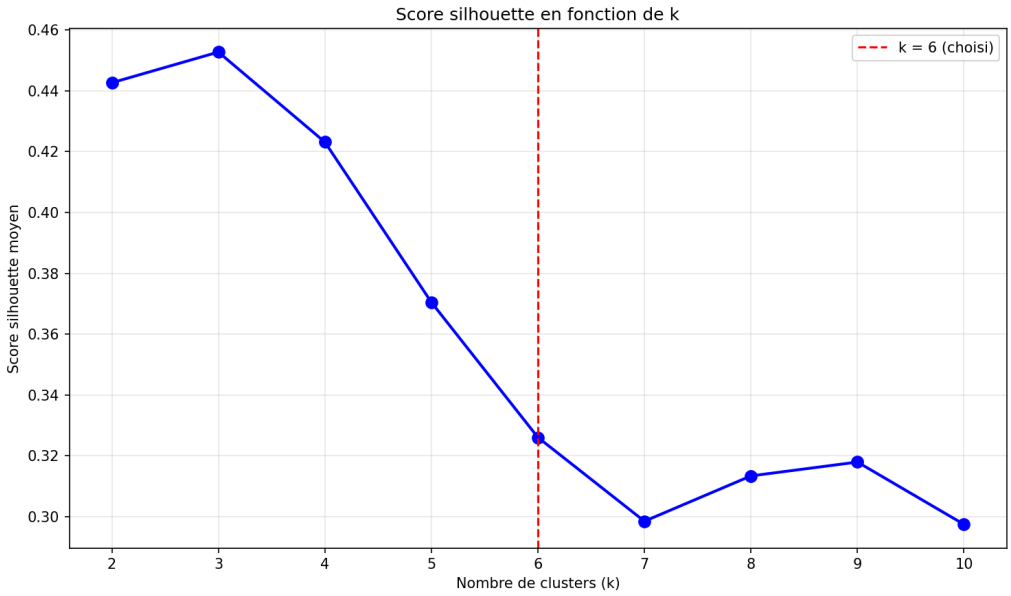

FIGURE 8 – Score silhouette moyen en fonction de k

4. Standardisation (StandardScaler)
5. KMeans ($k = 6$) $\rightarrow$ ajout de la colonne `cluster`
6. Export $\rightarrow$ `housing_data_knn_clustered.csv` (20 640 lignes, 11 colonnes)

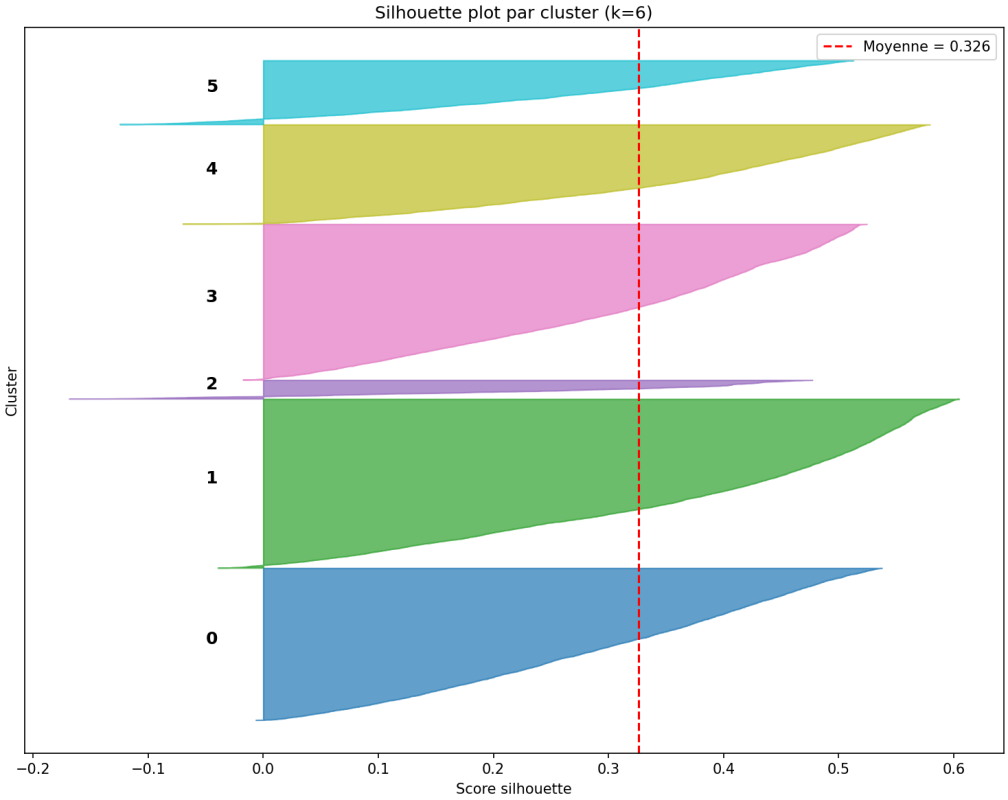

FIGURE 9 – Silhouette plot par cluster (k=6)